

奇异值分解 (SVD)



漫漫成长
算法工程师

4,691 人赞同了该文章

以下内容来自刘建平Pinard-博客园的学习笔记，总结如下：

奇异值分解(Singular Value Decomposition, 以下简称SVD)是在机器学习领域广泛应用的算法, 它不光可以用于降维算法中的特征分解, 还可以用于推荐系统, 以及自然语言处理等领域。是很多机器学习算法的基石。本文就对SVD的原理做一个总结, 并讨论在PCA降维算法中是如何运用SVD的。

1. 回顾特征值和特征向量

首先回顾下特征值和特征向量的定义如下：

$$Ax = \lambda x$$

其中 A 是一个 $n \times n$ 矩阵, x 是一个 n 维向量, 则 λ 是矩阵 A 的一个特征值, 而 x 是矩阵 A 的特征值 λ 所对应的特征向量。

求出特征值和特征向量有什么好处呢? 就是我们可以将矩阵 A 特征分解。如果我们求出了矩阵 A 的 n 个特征值 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$, 以及这 n 个特征值所对应的特征向量 w_1, w_2, \dots, w_n ,

那么矩阵 A 就可以用下式的特征分解表示：

$$A = W \Sigma W^{-1}$$

其中 W 是这 n 个特征向量所张成的 $n \times n$ 维矩阵, 而 Σ 为这 n 个特征值为主对角线的 $n \times n$ 维矩阵。

一般我们会把 W 的这 n 个特征向量标准化, 即满足 $\|w_i\|_2 = 1$, 或者 $w_i^T w_i = 1$, 此时 W 的

n 个特征向量为标准正交基, 满足 $W^T W = I$, 即 $W^T = W^{-1}$, 也就是说 W 为酉矩阵。

这样我们的特征分解表达式可以写成

$$A = W \Sigma W^T$$

注意到要进行特征分解, 矩阵 A 必须为方阵。

那么如果 A 不是方阵, 即行和列不相同, 我们还可以对矩阵进行分解吗? 答案是可以, 此时我们的SVD登场了。


2. SVD的定义

SVD也是对矩阵进行分解, 但是和特征分解不同, SVD并不要求要分解的矩阵为方阵。假设我们的矩阵 A 是一个 $m \times n$ 的矩阵, 那么我们定义矩阵 A 的SVD为：

$$A = U \Sigma V^T$$

其中 U 是一个 $m \times m$ 的矩阵, Σ 是一个 $m \times n$ 的矩阵, 除了主对角线上的元素以外全为0, 主对角线上的每个元素都称为奇异值, V 是一个 $n \times n$ 的矩阵。 U 和 V 都是酉矩阵, 即满足

$U^T U = I, V^T V = I$ 。下图可以很形象的看出上面SVD的定义：



那么我们如何求出SVD分解后的U,Σ,V这三个矩阵呢?

如果我们将A的转置和A做矩阵乘法,那么会得到 $n \times n$ 的一个方阵 $A^T A$ 。既然 $A^T A$ 是方阵,那么我们就可以进行特征分解,得到的特征值和特征向量满足下式:

$$(A^T A)v_i = \lambda_i v_i$$

这样我们就可以得到矩阵 $A^T A$ 的 n 个特征值和对应的 n 个特征向量 v 了。将 $A^T A$ 的所有特征向量张成一个 $n \times n$ 的矩阵 V ,就是我们SVD公式里面的 V 矩阵了。一般我们将 V 中的每个特征向量叫做A的右奇异向量。

如果我们将A和A的转置做矩阵乘法,那么会得到 $m \times m$ 的一个方阵 AA^T 。既然 AA^T 是方阵,那么我们就可以进行特征分解,得到的特征值和特征向量满足下式:

$$(AA^T)u_i = \lambda_i u_i$$

这样我们就可以得到矩阵 AA^T 的 m 个特征值和对应的 m 个特征向量 u 了。将 AA^T 的所有特征向量张成一个 $m \times m$ 的矩阵 U ,就是我们SVD公式里面的 U 矩阵了。一般我们将 U 中的每个特征向量叫做A的左奇异向量。

U 和 V 我们都求出来了,现在就剩下奇异值矩阵 Σ 没有求出了。

由于 Σ 除了对角线上是奇异值其他位置都是0,那我们只需要求出每个奇异值 σ 就可以了。

我们注意到:

$$A = U\Sigma V^T \Rightarrow AV = U\Sigma V^T V \Rightarrow AV = U\Sigma \Rightarrow Av_i = \sigma_i u_i \Rightarrow \sigma_i = Av_i / u_i$$

这样我们可以求出我们的每个奇异值,进而求出奇异值矩阵 Σ 。

上面还有一个问题没有讲,就是我们说 $A^T A$ 的特征向量组成的就是我们SVD中的 V 矩阵,而

AA^T 的特征向量组成的就是我们SVD中的 U 矩阵,这有什么根据吗?这个其实很容易证明,我们以 V 矩阵的证明为例。

$$A = U\Sigma V^T \Rightarrow A^T = V\Sigma U^T \Rightarrow A^T A = V\Sigma U^T U\Sigma V^T = V\Sigma^2 V^T$$

上式证明使用了 $U^T U = I, \Sigma^T = \Sigma$ 。可以看出 $A^T A$ 的特征向量组成的就是我们SVD中的 V 矩阵。类似的方法可以得到 AA^T 的特征向量组成的就是我们SVD中的 U 矩阵。

进一步我们还可以看出我们的特征值矩阵等于奇异值矩阵的平方,也就是说特征值和奇异值满足如下关系:

$$\sigma_i = \sqrt{\lambda_i}$$

这样也就是说,我们可以不用 $\sigma_i = \frac{Av_i}{u_i}$ 来计算奇异值,也可以通过求出 $A^T A$ 的特征值取平方根来求奇异值。

这里我们用一个简单的例子来说明矩阵是如何进行奇异值分解的。我们的矩阵A定义为：

$$\mathbf{A} = \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix}$$

首先求出 $\mathbf{A}^T \mathbf{A}$ 和 $\mathbf{A} \mathbf{A}^T$

$$\begin{aligned} \mathbf{A}^T \mathbf{A} &= \begin{pmatrix} 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \\ \mathbf{A} \mathbf{A}^T &= \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 1 \end{pmatrix} \end{aligned}$$

进而求出 $\mathbf{A}^T \mathbf{A}$ 的特征值和特征向量：

$$\lambda_1 = 3; v_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}; \lambda_2 = 1; v_2 = \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$$

接着求出 $\mathbf{A} \mathbf{A}^T$ 的特征值和特征向量：

$$\lambda_1 = 3; u_1 = \begin{pmatrix} 1/\sqrt{6} \\ 2/\sqrt{6} \\ 1/\sqrt{6} \end{pmatrix}; \lambda_2 = 1; u_2 = \begin{pmatrix} 1/\sqrt{2} \\ 0 \\ -1/\sqrt{2} \end{pmatrix}; \lambda_3 = 0; u_3 = \begin{pmatrix} 1/\sqrt{3} \\ -1/\sqrt{3} \\ 1/\sqrt{3} \end{pmatrix}$$

利用 $\mathbf{A} v_i = \sigma_i u_i, i = 1, 2$ 求奇异值：

$$\begin{aligned} \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} &= \sigma_1 \begin{pmatrix} 1/\sqrt{6} \\ 2/\sqrt{6} \\ 1/\sqrt{6} \end{pmatrix} \Rightarrow \sigma_1 = \sqrt{3} \\ \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} &= \sigma_2 \begin{pmatrix} 1/\sqrt{2} \\ 0 \\ -1/\sqrt{2} \end{pmatrix} \Rightarrow \sigma_2 = 1 \end{aligned}$$

也可以用 $\sigma_i = \sqrt{\lambda_i}$ 直接求出奇异值为 $\sqrt{3}$ 和 1。

最终得到A的奇异值分解为：

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T = \begin{pmatrix} 1/\sqrt{6} & 1/\sqrt{2} & 1/\sqrt{3} \\ 2/\sqrt{6} & 0 & -1/\sqrt{3} \\ 1/\sqrt{6} & -1/\sqrt{2} & 1/\sqrt{3} \end{pmatrix} \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

4. SVD的一些性质


对于奇异值,它跟我们特征分解中的特征值类似,在奇异值矩阵中也是按照从大到小排列,而且奇异值的减少特别的快,在很多情况下,前10%甚至1%的奇异值的和就占了全部的奇异值之和的99%以上的比例。

也就是说,我们也可以用最大的k个的奇异值和对应的左右奇异向量来近似描述矩阵。

也就是说：

$$\mathbf{A}_{m \times n} = \mathbf{U}_{m \times m} \mathbf{\Sigma}_{m \times n} \mathbf{V}_{n \times n}^T \approx \mathbf{U}_{m \times k} \mathbf{\Sigma}_{k \times k} \mathbf{V}_{k \times n}^T$$

其中k要比n小很多,也就是一个大的矩阵A可以用三个小的矩阵 $\mathbf{U}_{m \times k}, \mathbf{\Sigma}_{k \times k}, \mathbf{V}_{k \times n}^T$ 来表示。如下图所示,现在我们的矩阵A只需要灰色的部分的三个小矩阵就可以近似描述了。



由于这个重要的性质，SVD可以用于PCA降维，来做数据压缩和去噪。也可以用于推荐算法，将用户和喜好对应的矩阵做特征分解，进而得到隐含的用户需求来做推荐。同时也可以用于NLP中的算法，比如潜在语义索引（LSI）。

下面我们就对SVD用于PCA降维做一个介绍。

5. SVD用于PCA

PCA降维，需要找到样本协方差矩阵 $X^T X$ 的最大的d个特征向量，然后用这最大的d个特征向量张成的矩阵来做低维投影降维。可以看出，在这个过程中需要先求出协方差矩阵 $X^T X$ ，当样本数多样本特征数也多的时候，这个计算量是很大的。

注意到我们的SVD也可以得到协方差矩阵 $X^T X$ 最大的d个特征向量张成的矩阵，但是SVD有个好处，有一些SVD的实现算法可以不求先求出协方差矩阵 $X^T X$ ，也能求出我们的右奇异矩阵V。也就是说，我们的PCA算法可以不用做特征分解，而是做SVD来完成。这个方法在样本量很大的时候很有效。实际上，scikit-learn的PCA算法的背后真正的实现就是用的SVD，而不是我们我们认为的暴力特征分解。

另一方面，注意到PCA仅仅使用了我们SVD的右奇异矩阵，没有使用左奇异矩阵，那么左奇异矩阵有什么用呢？

假设我们的样本是 $m \times n$ 的矩阵X，如果我们通过SVD找到了矩阵 XX^T 最大的d个特征向量张成的 $m \times d$ 维矩阵U，则我们如果进行如下处理：

$$X'_{d \times n} = U^T_{d \times m} X_{m \times n}$$

可以得到一个 $d \times n$ 的矩阵X'，这个矩阵和我们原来的 $m \times n$ 维样本矩阵X相比，行数从m减到了k，可见对行数进行了压缩。

左奇异矩阵可以用于行数的压缩。

右奇异矩阵可以用于列数即特征维度的压缩，也就是我们的PCA降维。

6. SVD小结

SVD作为一个很基本的算法，在很多机器学习算法中都有它的身影，特别是在现在的大数据时代，由于SVD可以实现并行化，因此更是大展身手。

SVD的缺点是分解出的矩阵解释性往往不强，有点黑盒子的味道，不过这不影响它的使用。



编辑于 2017-10-12 12:38

数据降维 机器学习

写下你的评论...



182 条评论


默认 最新

 **刘思黎** 

试着解释一下SVD矩阵：在我看来，SVD是对数据进行有效特征整理的过程。首先，对于一个 $m \times n$ 矩阵A，我们可以理解为其有m个数据，n个特征，（想象成一个n个特征组成的坐标系中的m个点），然而一般情况下，这n个特征并不是正交的，也就是说这n个特征并不能归纳这个数据集的特征。SVD的作用就相当于是一个坐标系变换的过程，从一个不标准的n维坐标系，转换为一个标准的k维坐标系，并且使这个数据集中的点，到这个新坐标系的欧式距离为最小值（也就是这些点在这个新坐标系中的投影方差最大化），其实就是一个最小二乘的过程。进一步，如何使数据在新坐标系中的投影最大化呢，那么我们就需要让这个新坐标系中的基尽可能的不相关，我们可以用协方差来衡量这种相关性。 $A^T \cdot A$ 中计算的便是 $n \times n$ 的协方差矩阵，每一个值代表着原来的n个特征之间的相关性。当对这个协方差矩阵进行特征分解之后，我们可以得到奇异值和右奇异矩阵，而这个右奇异矩阵则是一个新的坐标系，奇异值则对应这个新坐标系中每个基对于整体数据的影响大小，我们这时便可以提取奇异值最大的k个基，作为新的坐标，这便是PCA的原理。



2020-01-10 · 热评


 回复  408

 **究极无敌超大水果** ▸ **周论**

右奇异矩阵应该是固定点的数量，压缩冗余的特征，左奇异矩阵是固定这么多特征，去掉冗余的点。



2021-04-07

 回复  21


 **周论**

左奇异矩阵是不是就是把m看作特征，n看作数据的个数，原理是一样的对吧，只不过是样本数据的不同表示方法😁

2021-03-11



 回复  8


查看全部 26 条回复 >

 **00木水**

公式评论里面挂了，这里详细描述下，就是2.SVD的定义里的A转置A那里的证明，一个是U乘U转置为单位阵，这里公式打错，一个是中间的矩阵sigma是 $m \times n$ 维度，它的转置是 $n \times m$ ，并不相等，但它们相乘是对角方阵。


2018-01-20

 回复  65

 **张亿锋** 

我也发现了，你说的是对的

2018-02-14

 回复  3

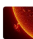
 **王同学**

我就说有问题。

2021-07-13



 回复  1


展开其他 2 条回复 >

 **舒适星球**

这个先算U V，再算中间矩阵的方法是错的!!! 浪费我一个下午加晚上排bug!!! 气死我了!!! （应该先算u或v再求中间矩阵推出v或u，按这种算法特征向量正负都无法确定）希望懂的人赞上去 别让这个文章害人了！



2021-05-23

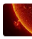
 回复  55

 **HK416**

兄啊，这是一个推导过程，来解释这些左右矩阵的含义的。而且也提到了，实际现在的算法并不是通过算协方差矩阵的特征值，因为这样非常慢。实际上MATLAB，numpy里面有大量算法可以直接输出SVD的左右矩阵以及奇异值，速度也很可观.....你要做算法或者码程序，应该要参考讲算法的文章，而不是这种。



2021-06-01

 回复  15


 **舒适星球** ▸ **HK416**

这算法错的没毛病吧😂大学生要做编程训练的 坑害了我是事实😂

2021-06-01



 回复  3

查看全部 11 条回复 >

 **知乎用户9YJDJs**


1里面A必须为实对称矩阵，实对称矩阵才有正交基让其对角化。一般的 $n \times n$ 矩阵，比如Jordan block是没法对角化的

2018-04-07

 回复  46

2018-12-20

回复 5

 **论分析**
这里的A默认是实对称阵或复正规阵吧😏

2019-12-13

回复 3

展开其他 1 条回复 >

 **曲面参数化**
分解出的矩阵解释性往往不强，深有体会。


2017-10-09

回复 33

 **Jeffery ▸ JunMa**
我一直不懂为什么分解出来的那三个矩阵有这样的物理含义。。

2017-11-08

回复 11

 **让我缓一缓**
本质是基变换造成的"点"的坐标表示方式不同，想要解释清楚，还是得理解矩阵论的思想。我认为基变换是本质，点（向量，数据）的坐标的变化是外在体现

2021-10-09

回复 4

查看全部 6 条回复 >

 **helloworld**
 $UTU=I, \Sigma T \Sigma = \Sigma^2$ 这里写错了

2019-07-07

回复 19

 **天明**
就在找你

2021-01-06

回复 3

 **秋离隼**
很棒的文章，让我这个傻子都看懂了SVD

2020-03-08

回复 8

 **忍冬之声**
我这个傻子还没看懂 是不是没救了

2021-05-18

回复 3

 **知乎用户7RHVBo**
那为啥SVD这么定义,你懂吗?

2021-09-23

回复 2

展开其他 1 条回复 >

 **知乎用户0H6wvp**
解释了怎么做,没有解释为什么这么做

2019-03-04

回复 8

 **YoungHojan ▸ 见证骑士的时刻**
你口气挺大😏


2022-01-06

回复 8

 **见证骑士的时刻**
解释了你能听懂吗


2021-12-13

回复 赞

 **我天吾啊**
包括这篇文章，都说使用SVD的优势是，不要求必须是方阵，可以不用计算协方差的特征值。可是你们在讲怎么计算SVD那两个矩阵的时候都是用协方差的特征值计算的，看了很多文章都搞不懂这点，而且PCA计算协方差矩阵特征值也不要求是方阵

2018-11-06

回复 8

 **刘亮 ▸ 计算机没前途**
我来回应一下吧，这里提的计算方法只是为了讲清楚这三个矩阵的含义，并且方便给出证明这么分解是对的。具体这么通过不计算协方差的特征值来求解 SVD 是有很多后续研究的，不是一篇简单的科普教程能讲清楚的，不求甚解的话，就记住高级的算法可以绕过这一步直接得到三个矩阵，如果实在感兴趣的话可以看一下 NIPS 2007 的文章 Fast

回复 44

**计算机没前途** ✓

这些人参考来参考去，也不正面回应一下

2020-02-06

● 回复 1

[查看全部 7 条回复](#) >**probe**

写的很清楚了，感谢。但有一个问题，第1节里，一般 $n \times n$ 矩阵的特征向量不一定正交，不是因为特征向量标准化后就是正交基了。实对称矩阵的不同特征值对应的特征向量必正交，比如PCA里的协方差矩阵就是实对称矩阵。还有一个疑问，

$$AA^T$$

和

$$A^T A$$

的特征值数量不同啊，一个是 m 个，一个是 n 个，难道只取其中相同的就行了吗？

2018-11-02

● 回复 7

**刘思黎** ✓

他们的非零特征值是相同的。简单证明： $A^T A x = \lambda \cdot x$ ，同时左乘 A 可以得到，
 $(A \cdot A^T) \cdot (Ax) = \lambda \cdot (Ax)$

2020-01-10

● 回复 14

**美国懂王** ▶ **刘思黎**不是 $Ax = \lambda \cdot x$ ？ $A^T A x = \lambda \cdot x$ 怎么来的？

2020-08-04

● 回复 1

[查看全部 8 条回复](#) >**壮壮** 🏠

我们的PCA算法可以不用做特征分解，而是做SVD来完成 - 不懂，svd具体是怎么求 v 和特征值的呢？具体算法说明能推荐一下吗？谢谢

2017-11-27

● 回复 6

**网络罗宾汉**

不好意思，我理解错了，作者这里的 X 是 $m \times d$ 的， m 是样本数， d 是单个样本向量的维数，和西瓜书是反着的

2019-11-26

● 回复 4

**流年**

说的对啊!!!

2021-03-23

● 回复 赞

**seezen**

也能求出我们的右奇异矩阵但是SVD有个好处，有一些SVD的实现算法可以不先求出协方差矩阵 Σ ，也能求出我们的右奇异矩阵 V 。有哪些算法。。

2018-09-13

● 回复 1

**Dosea**

看了这么多SVD概念，这个看懂了，谢谢 🙏

2017-11-16

● 回复 7

**白玉汤**

哪些SVD的算法可以不先求出协方差矩阵

$$X^T X$$
，也能求出我们的右奇异矩阵？

2018-06-04

● 回复 6

**caa**

power method或者贪心算法，前者是估计值，后者可槽性太难但准确

2019-06-23

● 回复 2

**Alvin he** ▶ **caa**

这也能抓到你？

2022-01-21

● 回复 赞

**李的摸鱼日记** ✓

脑成像一个很普遍的算法里面用过SVD，用于去噪音。

2017-10-09

● 回复 6

**Hello王叔叔** 🏠

2019-03-29

回复 7


 **chaseligher**

您好，可以推荐一下相关的这篇文章吗？谢谢您

02-20

回复 赞


展开其他 1 条回复 >

 **我不坏**

写的是不错，但在矩阵表示的时候与常识不一样，导致让人困惑，设X为数据，通常为d*n维，其中d为特征维，n为数量维，讲解中刚好相反。

2018-07-21

回复 5

 **luxcgo**


“一般我们会把W的这n个特征向量标准化，即满足 $\|w_i\|_2 = 1$ ，或者 $w_i^T w_i = 1$ ，此时W的n个特征向量为标准正交基”

是不是只有实对称矩阵才能做这种标准正交的操作，不是任意的矩阵都有这种性质吧？



2019-02-21


回复 3

 **在美国懂王**

特征根可以相同，只要满足（具有k重特征值λ，必有k个线性无关的特征向量）就可以了

2021-03-19

回复 1

 **在美国懂王**

我明白你说的意思。但我试过几次，特征根相同的话，最后乘起来好像不是最初的矩阵

2021-03-19

回复 赞


展开其他 2 条回复 >

 **小钳子**

我的算法也用到特征值，这个计算量真的是。。。需要并行处理

2017-10-10

回复 3

 **木耳机**

感谢 🙏

2018-01-07

回复 2

[点击查看全部评论 >](#)

写下你的评论...

文章被以下专栏收录




控制系统设计

推荐阅读

奇异值分解（SVD）

SVD(Singular Value Decomposition, 奇异值分解)是线性代数中既优雅又强大的工具, 它揭示了矩阵最本质的变换. 使用SVD对矩阵进行分解, 能得到代表矩阵最本质变化的矩阵元素. 这就好比一个...



奇异值分解（SVD）

奇异值分解(SVD)

欢迎关注我们的微信公众号“人工智能LeadAI”（ID: atleadai）最近两天都在看奇异值分解及其在推荐系统和图像压缩方面的应用, 这部分知识比较散也比较难理解, 看代码不是很好懂, 所以通过编...

23、奇异值分解:

本章内容包含了: S的通用计算方法SVI SVD常见的疑问在OpenCV求解SVD的应用场景S统、协同过滤和相似

